

ALHE Z11
Jarosław Arabas
wykład 12

Ewolucja różnicowa

algorytm differential evolution

inicjuj $\mathbf{P}(0) \leftarrow \{\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_\mu\}$

$t \leftarrow 0$

while ! stop

for ($i \in 1:\mu$)

$\mathbf{x}_j \leftarrow \text{select}(\mathbf{P}(t))$

$\mathbf{x}_k, \mathbf{x}_l \leftarrow \text{sample}(\mathbf{P}(t))$

$\mathbf{y} \leftarrow \mathbf{x}_j + F(\mathbf{x}_k - \mathbf{x}_l)$

$\mathbf{z} \leftarrow \text{crossover}(\mathbf{x}_i, \mathbf{y})$

$\mathbf{x}_i \leftarrow \text{tournament}(\mathbf{x}_i, \mathbf{z})$

$t \leftarrow t + 1$

sample jest procesem wyboru pary punktów z jednakowym p-stwem

crossover jest operacją krzyżowania wymieniającego

Typy ewolucji różnicowej

- Typ selekcji
 - wybór losowego (rand)
 - wybór najlepszego w populacji (best)
- Typ krzyżowania
 - dwumianowe (bin)
 - wykładnicze (exp)
- Liczba par różnicowanych punktów – 1 albo 2
- Konwencja oznaczeń: DE/rand/1/bin

Typy krzyżowania

procedure binomial crossover

arguments: x, y

for ($i \in 1:n$)

if $a < c_r$

$z_i \leftarrow y_i$

else

$z_i \leftarrow x_i$

return z

procedure exponential crossover

arguments: x, y

$i \leftarrow 1$

while ($i \leq n$)

if $a < c_r$

$z_i \leftarrow y_i$

else break

while ($i \leq n$)

$z_i \leftarrow x_i$

return z

a jest zmienną losową o rozkładzie jednostajnym w $(0,1)$

c_r jest parametrem

Algorytm ewolucyjny wypukła funkcja celu

- Model populacji nieskończonej
- Dystrybuanta empiryczna punktów populacji (skokowa) → dystrybuanta rozkładu próbkowania (ciągła)

DE/rand/1

wypukła funkcja celu

- Wariancja punktów po selekcji v_P
- Wariancja punktów po mutacji

$$v_O = v_P + F^2(v_P + v_P) = v_P(1 + 2F^2)$$


- Krzyżowanie zmienia wariancję (wzór dla bin)

$$v_C = (1 + 2F^2(1 - c_r))v_P$$

- Wariancja po sukcesji – kto umie obliczyć?
(pierwsze zgłoszenie zalicza drugie kolokwium,
decyduje moment przyjscia z prawidłowym
rozwiązaniem poczty elektronicznej lub osoby)

DE/rand/1

wypukła funkcja celu -
wariancja po sukcesji



DE/rand/1

wypukła funkcja celu

- Wariancja punktów po sukcesji

$$v_P(t+1) = k(F) v_P(t) \quad 0 < k < 1$$

- Równowagowa wariancja populacji:

$$v_P(\infty) = 0$$

- A dla alg. ewolucyjnego
(np. selekcja turniejowa, $s=2$, $pc=0$)

$$v_P(\infty) = \frac{\pi}{2} v_m$$

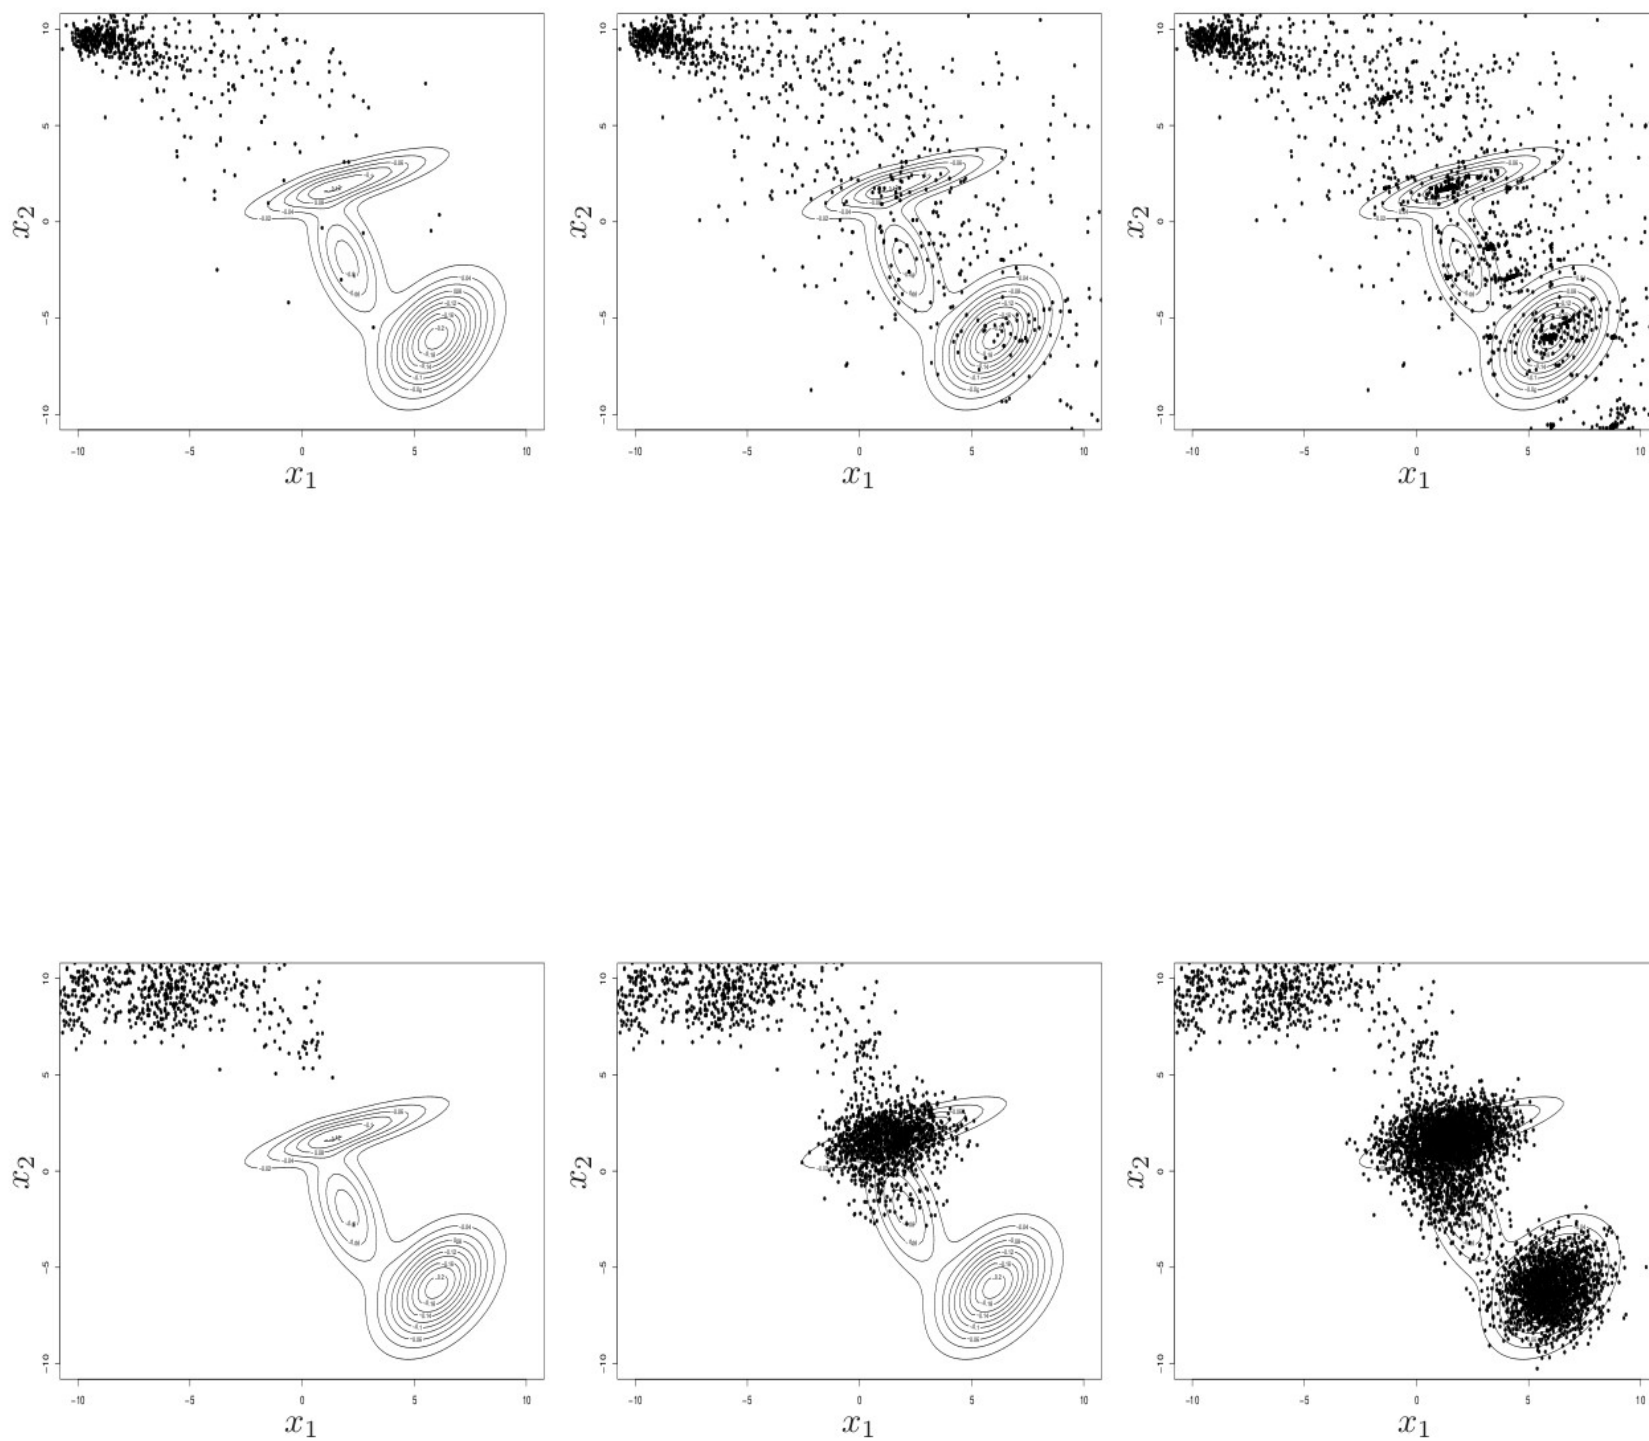




Fig. 6 Set of chromosomes generated by the GMEA algorithm with $\mu = 16$ points in population and mutation standard deviation equal to 0.6 : consecutive



Algorytm ewolucyjny

- Algorytm ewolucyjny jest techniką **adaptacji rozkładu populacji**
- Celem jest maksymalizacja wartości oczekiwanej jakości generowanych punktów
- Środek populacji – najlepszy estymator ekstremum lokalnego dla funkcji symetrycznej
- *Survival of the fittest vs. survival of the flattest*

Metoda EDA

Estimation of Distribution Algorithm

algorithm **EDA**

initialize $\mathbf{m}(0), \mathbf{C}(0)$

$t \leftarrow 0$

while ! *stop*

$P(t) \leftarrow \text{sample } N(\mathbf{m}(t), \mathbf{C}(t))$

Wariant z rozkładem normalnym

$O(t) \leftarrow \text{select}(P(t))$

opcjonalne

$(\mathbf{m}(t+1), \mathbf{C}(t+1)) \leftarrow \text{update}(O(t), \mathbf{m}(t), \mathbf{C}(t))$

$t \leftarrow t + 1$

Metoda EDA

Estimation of Distribution Algorithm

- UMDA (Univariate Marginal Distribution)
- Wartość oczekiwana i wariancja estymowana z próby jako


$$\mathbf{m}(t+1)_j \leftarrow \sum_{i=1}^{\mu} w(i) x_{ij}$$

$$\mathbf{C}(t+1)_{jj} \leftarrow \sum_{i=1}^{\mu} w(i) (x_{ij} - m(t+1)_j)^2$$


$$\mathbf{C}(t+1)_{ij} = 0 \quad i \neq j$$

$$w(i) = \frac{q(\mathbf{x}_i)}{\sum q(\mathbf{x}_i)}$$


EDA



EDA




EDA




CMAES

Covariance Matrix Adaptation Evolution Strategy




CMAES

Covariance Matrix Adaptation Evolution Strategy




CMAES

Covariance Matrix Adaptation Evolution Strategy




CMAES

evolution path




Podążanie w +/- zgodnych kierunkach



Populacja fluktuuje w jednym obszarze

CMAES

Covariance Matrix Adaptation Evolution Strategy



Na podstawie selekcji adaptuje się
kształt macierzy kowariancji

Jej skala zależy od ścieżki ewolucji

$$+ \text{[Diagram of a search path with blue, red, and magenta points and arrows]} = \text{CMAES}$$

algorithm **CMAES**

initialize $\mathbf{m}(0), \mathbf{C}(0)$

$t \leftarrow 0$

while ! stop

$P(t) \leftarrow \text{sample } N(\mathbf{m}(t), \sigma(t)\mathbf{C}(t))$

$\mathbf{m}(t+1) \leftarrow (\overline{P(t)})$

$\mathbf{p}_c(t+1) \leftarrow (1-c_c)\mathbf{p}_c(t) + \sqrt{c_c(2-c_c)} \frac{c_w}{\sigma(t)} (\overline{P(t+1)} - \overline{P(t)})$

$\mathbf{p}_s(t+1) \leftarrow (1-c_c)\mathbf{p}_s(t) + \sqrt{c_c(2-c_c)} \frac{c_w}{\sigma(t)} \mathbf{D}(t) (\overline{P(t+1)} - \overline{P(t)})$

$\sigma(t+1) = \sigma(t) \exp\left(\frac{1}{de} (\|\mathbf{p}_s(t+1)\| - e)\right)$

$\mathbf{C}(t+1) \leftarrow (1-c_v)\mathbf{C}(t) + c_v \mathbf{p}_c(t+1)(\mathbf{p}_c(t+1))^T$

$$c_w = \frac{\sum w_i}{\sqrt{\sum (w_i)^2}}$$

$t \leftarrow t + 1$

$\mathbf{D}(t)$ – macierz wartości własnych macierzy $\mathbf{C}(t)$

e – w. oczekiwana długości n -wymiarowego wektora standardowych normalnych zmiennych losowych